

TRABAJO PRÁCTICO

Análisis Exploratorio de Datos + Regresión Lineal



Agustín Musanti

31/05/2026

Certificación Avanzada en Data Science

PARTE A - REGRESIÓN

1) Indique el nombre del dataset, y la librería R o la página fuente del mismo.

El dataset utilizado en este trabajo es “**Credit**”, perteneciente a la librería “**ISLR2**” de R, que acompaña al libro “An Introduction to Statistical Learning, 2nd Edition” (James, Witten, Hastie and Tibshirani).

2) Identifique la variable a predecir (indique el nombre textual de la variable) y de qué trata el caso a predecir.

La variable a predecir es “Balance”, que representa el saldo promedio de deuda en la tarjeta de crédito de cada cliente, expresado en dólares estadounidenses. El caso consiste en predecir el nivel de endeudamiento de un cliente a partir de sus características financieras y demográficas, como el ingreso (**Income**), el límite de crédito (**Limit**), la calificación crediticia (**Rating**), la edad (**Age**), los años de educación (**Education**) y variables categóricas como género, estado civil y condición de estudiante. Este tipo de análisis resulta útil en la industria financiera para estimar el comportamiento de pago de los clientes y apoyar decisiones de otorgamiento de créditos.

3) Muestre un dim y un summary de la base

Se ejecutan las instrucciones **dim(Credit)** y **summary(Credit)** sobre el dataset cargado, obteniendo los siguientes resultados:

```
> dim(Credit)
[1] 400 11
> summary(Credit)
```

Income		Limit		Rating		Cards		Age		Education		Own		Student	
Min. : 10.35	Min. : 855	Min. : 93.0	Min. : 1.000	Min. : 23.00	Min. : 5.00	No :193	No :360								
1st Qu.: 21.01	1st Qu.: 3088	1st Qu.:247.2	1st Qu.:2.000	1st Qu.:41.75	1st Qu.:11.00	Yes:207	Yes: 40								
Median : 33.12	Median : 4622	Median :344.0	Median :3.000	Median :56.00	Median :14.00										
Mean : 45.22	Mean : 4736	Mean :354.9	Mean :2.958	Mean :55.67	Mean :13.45										
3rd Qu.: 57.47	3rd Qu.: 5873	3rd Qu.:437.2	3rd Qu.:4.000	3rd Qu.:70.00	3rd Qu.:16.00										
Max. :186.63	Max. :13913	Max. :982.0	Max. :9.000	Max. :98.00	Max. :20.00										

Married		Region		Balance	
No :155	East : 99	Min. : 0.00			
Yes:245	South:199	1st Qu.: 68.75			
	West :102	Median : 459.50			
		Mean : 520.01			
		3rd Qu.: 863.00			
		Max. :1999.00			


4) ¿Cuántos registros tiene la base? ¿Cuántas variables? ¿De qué tipo son las variables?

La base contiene **400** registros (observaciones) y **11** variables. En cuanto a sus tipos:

- 7 variables numéricas: **Income** (ingreso anual en miles de USD), **Limit** (límite de crédito), **Rating** (calificación crediticia), **Cards** (cantidad de tarjetas), **Age** (edad), **Education** (años de educación) y **Balance** (saldo de la tarjeta, variable a predecir).
- 4 variables categóricas: **Own** (propietario de vivienda: Yes/No), **Student** (estudiante: Yes/No), **Married** (casado/a: Yes/No) y **Region** (región: East/South/West).

5) Realice un histograma de la variable a predecir. ¿En qué rango se encuentran los valores?

Se realiza el histograma de la variable **Balance** (saldo de tarjeta de crédito en USD), variable cuantitativa a predecir.



Los valores de **Balance** se encuentran en el rango de 0 a 1.999 dólares aproximadamente. La distribución presenta asimetría positiva (sesgo a la derecha), con una fuerte concentración de observaciones en valores bajos, incluyendo clientes con saldo cero, y una frecuencia que decrece a medida que aumenta el saldo.

a) Para el título ingrese su nombre como “Histograma de Marcela” (o sea “Histograma de SuNombre”)

Título utilizado: “Histograma de Agustín”.

b) Elija un color para el gráfico. Tenga en cuenta que ingresa `colors()` en R verá que hay +500 colores posibles.

Color elegido: `steelblue`.

c) Indique el código R utilizado.

```
hist(Credit$Balance, main = "Histograma de Agustín", col = "steelblue")
```

PARTE B - Conjuntos

1) Considere su DNI para el seteo de la semilla y particione la base en un conjunto de entrenamiento y uno de testeo con la librería `caret`.

Indique el código R utilizado.

- Además, si su DNI termina en 0, 1, 2 ó 3 **Seteo $p=0.70$**
- Si su DNI termina en 4, 5, 6 ó 7 **Seteo $p=0.75$**
- Si su DNI termina en 8 ó 9 **Seteo $p=0.80$**

Considerando mi DNI como semilla y el valor $p = 0.75$ (dado que el DNI termina en 5), se particiona la base utilizando la función `createDataPartition` de la librería `caret`.

El código R utilizado fue:

```
library(caret)
```

```
set.seed(5505); particion = createDataPartition(y = Credit$Balance, p = 0.75, list = FALSE)
```

```
entreno = Credit[particion, ]
```

```
testeo = Credit[-particion, ]
```

2) Muestre un head y un summary del conjunto de entrenamiento y del conjunto de testeo.

Se ejecutan las instrucciones **head** y **summary** sobre ambos conjuntos para verificar la correcta partición de la base.

Conjunto de entrenamiento:

```
head(entreno)
```

Income	Limit	Rating	Cards	Age	Education	Own	Student	Married	Region	Balance
104.593	7075	514	4	71	11	No	No	No	West	580
148.924	9504	681	3	36	11	Yes	No	No	West	964
55.882	4897	357	2	68	16	No	No	Yes	South	331
80.180	8047	569	4	77	10	No	No	No	South	1151
71.408	7114	512	2	87	9	No	No	No	West	872
71.061	6819	491	3	41	19	Yes	Yes	Yes	East	1350

```
> summary(entreno)
```

Income		Limit		Rating		Cards		Age	
Min.	: 10.35	Min.	: 855	Min.	: 93.0	Min.	: 1.000	Min.	: 23.00
1st Qu.:	20.97	1st Qu.:	3098	1st Qu.:	251.0	1st Qu.:	2.000	1st Qu.:	41.00
Median :	33.02	Median :	4569	Median :	344.0	Median :	3.000	Median :	56.00
Mean :	44.13	Mean :	4688	Mean :	352.3	Mean :	2.957	Mean :	55.63
3rd Qu.:	55.88	3rd Qu.:	5765	3rd Qu.:	433.0	3rd Qu.:	4.000	3rd Qu.:	69.00
Max.	: 186.63	Max.	: 13414	Max.	: 949.0	Max.	: 9.000	Max.	: 87.00

Education		Own		Student		Married		Region		Balance	
Min.	: 5.00	No :	150	No :	269	No :	119	East :	73	Min.	: 0.0
1st Qu.:	11.00	Yes:	151	Yes:	32	Yes:	182	South:	156	1st Qu.:	70.0
Median :	14.00							West :	72	Median :	463.0
Mean :	13.39									Mean :	515.1
3rd Qu.:	16.00									3rd Qu.:	863.0
Max.	: 20.00									Max.	: 1809.0

Conjunto de testeo:

```
head(testeo)
```

```
  Income Limit Rating Cards Age Education Own Student Married Region Balance
1  14.891  3606   283    2  34         11   No       No       Yes  South    333
2 106.025  6645   483    3  82         15  Yes      Yes      Yes   West    903
3  20.996  3388   259    2  37         12  Yes      No       No    East    203
4  15.125  3300   266    5  66         13  Yes      No       No   South    279
5  43.682  6922   511    1  49          9   No      No      Yes   South   1081
6  19.144  3291   269    2  75         13  Yes      No       No    East    148
```

```
> summary(testeo)
```

```
      Income      Limit      Rating      Cards      Age
Min.   : 10.63  Min.   : 1300  Min.   :115.0  Min.   :1.00  Min.   :24.00
1st Qu.: 21.25  1st Qu.: 2922  1st Qu.:223.0  1st Qu.:2.00  1st Qu.:43.00
Median : 33.66  Median : 4712  Median :344.0  Median :3.00  Median :55.00
Mean   : 48.53  Mean   : 4882  Mean   :363.0  Mean   :2.96  Mean   :55.77
3rd Qu.: 63.13  3rd Qu.: 6385  3rd Qu.:459.5  3rd Qu.:4.00  3rd Qu.:70.50
Max.   :182.73  Max.   :13913  Max.   :982.0  Max.   :7.00  Max.   :98.00

      Education      Own      Student      Married      Region      Balance
Min.   : 6.00     No :43     No :91     No :36     East :26  Min.   : 0.0
1st Qu.:11.50    Yes:56    Yes: 8     Yes:63    South:43  1st Qu.: 34.5
Median :14.00                                     West :30  Median : 453.0
Mean   :13.64                                     Mean   : 534.9
3rd Qu.:16.00                                     3rd Qu.: 847.5
Max.   :19.00                                     Max.   :1999.0
```

Se observa que las distribuciones de las variables son consistentes entre ambos conjuntos, lo que indica que la partición estratificada realizada con `createDataPartition` mantuvo la representatividad de los datos.

3) ¿Cuántos registros quedaron en cada conjunto (entrenamiento y testeo) en total?

Para verificar la cantidad de registros en cada conjunto se utiliza la función `dim`.

Como resultado obtengo:

- Conjunto de entrenamiento: **301** registros y **11** variables.
- Conjunto de testeo: **99** registros y **11** variables.

En total, ambos conjuntos suman los **400** registros originales de la base, respetando la proporción $p = 0.75$ establecida para la partición (75% entrenamiento, 25% testeo).

PARTE C - MODELO PREDICTIVO DE REGRESIÓN LINEAL

1) Entrene un modelo de regresión lineal sobre el conjunto de entrenamiento. Justifique la elección de estas variables.

Se entrena un modelo de regresión lineal sobre el conjunto de entrenamiento, seleccionando como variables predictoras **Limit**, **Rating** e **Income**. La elección no fue automática (utilizando todas las variables disponibles) sino que respondió a un criterio económico-financiero, considerando los tres factores fundamentales que determinan el saldo de deuda de un cliente en una tarjeta de crédito:

- **Limit** representa la capacidad de endeudamiento otorgada por la entidad financiera, es decir, el techo máximo que el cliente puede gastar.
- **Rating** refleja el perfil crediticio del cliente, indicador de su solvencia y comportamiento histórico de pago.
- **Income** mide la capacidad de pago del cliente, asociada a su nivel de ingresos.

Estas tres variables condensan la lógica básica del análisis crediticio (cuánto puede gastar, qué tan confiable es y cuánto puede afrontar), por lo que resultan las más representativas para modelar el comportamiento del saldo (**Balance**).

2) Realice predicciones sobre el conjunto de testeo y calcule el Error Cuadrático Medio (MSE) y su raíz (RMSE). Comente los resultados obtenidos y grafique.

Una vez entrenado el modelo, se generan las predicciones sobre el conjunto de testeo utilizando la función **predict**. Para evaluar la calidad de las predicciones se calculan dos métricas:

MSE (Error Cuadrático Medio): promedio de los errores al cuadrado, expresado en USD².


RMSE (Raíz del Error Cuadrático Medio): raíz cuadrada del MSE, expresado en USD, lo que facilita su interpretación al estar en la misma unidad que la variable predicha.

Resultados obtenidos:

MSE: 21.130,44 USD²

RMSE: 145,36 USD

Esto indica que, en promedio, las predicciones del modelo se desvían en aproximadamente **145,36 dólares** respecto del saldo real de cada cliente en el conjunto de testeo.



3) A partir del gráfico y las métricas obtenidas, indique su conclusión sobre el desempeño del modelo. ¿Qué observaciones puede realizar respecto a los aciertos y errores de la predicción?

El modelo de regresión lineal entrenado presenta un desempeño sólido en general, con un RMSE de **145,36 USD** sobre una variable cuyo rango va de **0** a **~2.000 USD** (aproximadamente un 7% del rango total). Esto indica que las tres variables seleccionadas capturan adecuadamente la lógica económica del saldo de tarjeta.

Aciertos: para clientes con saldo medio y alto (**Balance > 500 USD**), los puntos se ubican muy cerca de la línea de predicción perfecta, mostrando que el modelo identifica correctamente el comportamiento de los clientes con deuda activa.

Errores principales: la mayor debilidad se observa en los clientes con **Balance = 0** (sin deuda activa), donde el modelo predice valores negativos, lo cual no tiene sentido económico ya que un saldo de tarjeta no puede ser inferior a cero. Esto evidencia una limitación estructural de la regresión lineal: al no contar con restricciones de rango, extrapola hacia valores imposibles. Adicionalmente, en saldos muy altos (>**1.500 USD**) el modelo tiende a subestimar levemente.

En conclusión, se trata de un primer modelo simple y consistente con criterios financieros, útil como línea base, aunque su precisión podría mejorarse incorporando técnicas que respeten la naturaleza no negativa de la variable o incluyendo predictores adicionales.

ANEXO - CÓDIGO R

```
# Parte A - Regresión

# Carga de librería y dataset

library(ISLR2)

data(Credit)

# Dimensiones y resumen estadístico de la base

dim(Credit)

summary(Credit)

# Histograma de la variable a predecir (Balance)

hist(Credit$Balance, main = "Histograma de Agustín", col = "steelblue")

# Parte B - Conjuntos

# Carga de librería caret para la partición

library(caret)

# Partición en conjunto de entrenamiento (75%) y testeo (25%)

# Semilla: DNI

set.seed(5505); particion = createDataPartition(y = Credit$Balance, p =
0.75, list = FALSE)

entreno = Credit[particion, ]

testeo = Credit[-particion, ]

# Exploración del conjunto de entrenamiento

head(entreno)

summary(entreno)

# Exploración del conjunto de testeo
```

```
head(testeo)

summary(testeo)

# Cantidad de registros en cada conjunto

dim(entreno)

dim(testeo)

# Parte C - Modelo predictivo de Regresión Lineal

# Entrenamiento del modelo lineal con 3 predictores económicos:

# Limit, Rating e Income

modelo = lm(Balance ~ Limit + Rating + Income, data = entreno)

summary(modelo)

# Predicción sobre el conjunto de testeo

pred = predict(modelo, newdata = testeo)

# Métricas de error

mse = mean((testeo$Balance - pred)^2)

rmse = sqrt(mse)

cat("MSE del modelo en testeo:", round(mse, 2), "\n")

cat("RMSE:", round(rmse, 2), "USD\n")

# Gráfico predicho vs real

plot(testeo$Balance, pred,
      main = "Predicho vs Real - Modelo Lineal",
      xlab = "Balance real (USD)",
      ylab = "Balance predicho (USD)",
      col = "steelblue",
      pch = 19)

abline(0, 1, col = "red", lwd = 2, lty = 2)
```