

TRABAJO PRÁCTICO N°1

Análisis Exploratorio de Datos



Agustín Musanti

42.835.505

Certificación Avanzada en Data Science

PARTE A - REGRESIÓN

1) Indique el nombre del dataset, y la librería R o la página fuente del mismo.

El dataset utilizado en este trabajo es “**Credit**”, perteneciente a la librería “**ISLR2**” de R, que acompaña al libro “An Introduction to Statistical Learning, 2nd Edition” (James, Witten, Hastie and Tibshirani).

2) Identifique la variable a predecir (indique el nombre textual de la variable) y de qué trata el caso a predecir.

La variable a predecir es “Balance”, que representa el saldo promedio de deuda en la tarjeta de crédito de cada cliente, expresado en dólares estadounidenses. El caso consiste en predecir el nivel de endeudamiento de un cliente a partir de sus características financieras y demográficas, como el ingreso (**Income**), el límite de crédito (**Limit**), la calificación crediticia (**Rating**), la edad (**Age**), los años de educación (**Education**) y variables categóricas como género, estado civil y condición de estudiante. Este tipo de análisis resulta útil en la industria financiera para estimar el comportamiento de pago de los clientes y apoyar decisiones de otorgamiento de créditos.

3) Muestre un dim y un summary de la base

Se ejecutan las instrucciones **dim(Credit)** y **summary(Credit)** sobre el dataset cargado, obteniendo los siguientes resultados:

```
> dim(Credit)
[1] 400 11
> summary(Credit)
```

Income		Limit		Rating		Cards		Age		Education		Own		Student	
Min.	: 10.35	Min.	: 855	Min.	: 93.0	Min.	:1.000	Min.	:23.00	Min.	: 5.00	No	:193	No	:360
1st Qu.	: 21.01	1st Qu.	: 3088	1st Qu.	:247.2	1st Qu.	:2.000	1st Qu.	:41.75	1st Qu.	:11.00	Yes	:207	Yes	: 40
Median	: 33.12	Median	: 4622	Median	:344.0	Median	:3.000	Median	:56.00	Median	:14.00				
Mean	: 45.22	Mean	: 4736	Mean	:354.9	Mean	:2.958	Mean	:55.67	Mean	:13.45				
3rd Qu.	: 57.47	3rd Qu.	: 5873	3rd Qu.	:437.2	3rd Qu.	:4.000	3rd Qu.	:70.00	3rd Qu.	:16.00				
Max.	:186.63	Max.	:13913	Max.	:982.0	Max.	:9.000	Max.	:98.00	Max.	:20.00				

Married		Region		Balance	
No	:155	East	: 99	Min.	: 0.00
Yes	:245	South	:199	1st Qu.	: 68.75
		West	:102	Median	: 459.50
				Mean	: 520.01
				3rd Qu.	: 863.00
				Max.	:1999.00


4) ¿Cuántos registros tiene la base? ¿Cuántas variables? ¿De qué tipo son las variables?

La base contiene **400** registros (observaciones) y **11** variables. En cuanto a sus tipos:

- 7 variables numéricas: **Income** (ingreso anual en miles de USD), **Limit** (límite de crédito), **Rating** (calificación crediticia), **Cards** (cantidad de tarjetas), **Age** (edad), **Education** (años de educación) y **Balance** (saldo de la tarjeta, variable a predecir).
- 4 variables categóricas: **Own** (propietario de vivienda: Yes/No), **Student** (estudiante: Yes/No), **Married** (casado/a: Yes/No) y **Region** (región: East/South/West).

5) Realice un histograma de la variable a predecir. ¿En qué rango se encuentran los valores?

Se realiza el histograma de la variable **Balance** (saldo de tarjeta de crédito en USD), variable cuantitativa a predecir.



Los valores de **Balance** se encuentran en el rango de **0** a **1.999** dólares aproximadamente. La distribución presenta asimetría positiva (sesgo a la derecha), con una fuerte concentración de observaciones en valores bajos, incluyendo clientes con saldo cero, y una frecuencia que decrece a medida que aumenta el saldo.

a) Para el título ingrese su nombre como "Histograma de Marcela" (o sea "Histograma de SuNombre")

Título utilizado: "Histograma de Agustín".

b) Elija un color para el gráfico. Tenga en cuenta que ingresa `colors()` en R verá que hay +500 colores posibles.

Color elegido: `steelblue`.

c) Indique el código R utilizado.

```
hist(Credit$Balance, main = "Histograma de Agustín", col = "steelblue")
```

PARTE B - Conjuntos

1) Considere su DNI para el seteo de la semilla y particione la base en un conjunto de entrenamiento y uno de testeo con la librería `caret`.

Indique el código R utilizado.

- Además, si su DNI termina en 0, 1, 2 ó 3 **Setee $p=0.70$**
- Si su DNI termina en 4, 5, 6 ó 7 **Setee $p=0.75$**
- Si su DNI termina en 8 ó 9 **Setee $p=0.80$**

Considerando mi DNI (42835505) como semilla y el valor $p = 0.75$ (dado que el DNI termina en 5), se particiona la base utilizando la función `createDataPartition` de la

librería **caret**.

El código R utilizado fue:

```
library(caret)
```

```
set.seed(42835505); particion = createDataPartition(y = Credit$Balance, p = 0.75, list = FALSE)
```

```
entreno = Credit[particion, ]
```

```
testeo = Credit[-particion, ]
```

2) Muestre un head y un summary del conjunto de entrenamiento y del conjunto de testeo.

Se ejecutan las instrucciones **head** y **summary** sobre ambos conjuntos para verificar la correcta partición de la base.

Conjunto de entrenamiento:

```
head(entreno)
```

Income	Limit	Rating	Cards	Age	Education	Own	Student	Married	Region	Balance
104.593	7075	514	4	71	11	No	No	No	West	580
148.924	9504	681	3	36	11	Yes	No	No	West	964
55.882	4897	357	2	68	16	No	No	Yes	South	331
80.180	8047	569	4	77	10	No	No	No	South	1151
71.408	7114	512	2	87	9	No	No	No	West	872
71.061	6819	491	3	41	19	Yes	Yes	Yes	East	1350

```
> summary(entreno)
```

Income		Limit		Rating		Cards		Age	
Min.	: 10.35	Min.	: 855	Min.	: 93.0	Min.	: 1.000	Min.	: 23.00
1st Qu.:	20.97	1st Qu.:	3098	1st Qu.:	251.0	1st Qu.:	2.000	1st Qu.:	41.00
Median :	33.02	Median :	4569	Median :	344.0	Median :	3.000	Median :	56.00
Mean :	44.13	Mean :	4688	Mean :	352.3	Mean :	2.957	Mean :	55.63
3rd Qu.:	55.88	3rd Qu.:	5765	3rd Qu.:	433.0	3rd Qu.:	4.000	3rd Qu.:	69.00
Max.	: 186.63	Max.	: 13414	Max.	: 949.0	Max.	: 9.000	Max.	: 87.00

Education		Own		Student		Married		Region		Balance	
Min.	: 5.00	No :	150	No :	269	No :	119	East :	73	Min.	: 0.0
1st Qu.:	11.00	Yes:	151	Yes:	32	Yes:	182	South:	156	1st Qu.:	70.0
Median :	14.00							West :	72	Median :	463.0
Mean :	13.39									Mean :	515.1
3rd Qu.:	16.00									3rd Qu.:	863.0
Max.	: 20.00									Max.	: 1809.0

Conjunto de testeo:

```
head(testeo)
  Income Limit Rating Cards Age Education Own Student Married Region Balance
1 14.891 3606   283    2  34      11   No      No      Yes  South    333
2 106.025 6645   483    3  82      15  Yes     Yes     Yes   West    903
3  20.996 3388   259    2  37      12  Yes     No      No    East    203
4  15.125 3300   266    5  66      13  Yes     No      No    South   279
5  43.682 6922   511    1  49       9   No     No      Yes   South  1081
6  19.144 3291   269    2  75      13  Yes     No      No    East   148

> summary(testeo)
      Income      Limit      Rating      Cards      Age
Min.   : 10.63   Min.   : 1300   Min.   :115.0   Min.   :1.00   Min.   :24.00
1st Qu.: 21.25   1st Qu.: 2922   1st Qu.:223.0   1st Qu.:2.00   1st Qu.:43.00
Median : 33.66   Median : 4712   Median :344.0   Median :3.00   Median :55.00
Mean   : 48.53   Mean   : 4882   Mean   :363.0   Mean   :2.96   Mean   :55.77
3rd Qu.: 63.13   3rd Qu.: 6385   3rd Qu.:459.5   3rd Qu.:4.00   3rd Qu.:70.50
Max.   :182.73   Max.   :13913   Max.   :982.0   Max.   :7.00   Max.   :98.00

      Education      Own      Student      Married      Region      Balance
Min.   : 6.00      No :43      No :91      No :36      East :26   Min.   : 0.0
1st Qu.:11.50     Yes:56     Yes: 8     Yes:63     South:43  1st Qu.: 34.5
Median :14.00                                     West :30   Median : 453.0
Mean   :13.64                                     Mean   : 534.9
3rd Qu.:16.00                                     3rd Qu.: 847.5
Max.   :19.00                                     Max.   :1999.0
```

Se observa que las distribuciones de las variables son consistentes entre ambos conjuntos, lo que indica que la partición estratificada realizada con `createDataPartition` mantuvo la representatividad de los datos.

3) ¿Cuántos registros quedaron en cada conjunto (entrenamiento y testeo) en total?

Para verificar la cantidad de registros en cada conjunto se utiliza la función `dim`.

Como resultado obtengo:

- Conjunto de entrenamiento: **301** registros y **11** variables.
- Conjunto de testeo: **99** registros y **11** variables.

En total, ambos conjuntos suman los **400** registros originales de la base, respetando la proporción $p = 0.75$ establecida para la partición (75% entrenamiento, 25% testeo).

ANEXO - CÓDIGO R

```
# Parte A - Regresión

# Carga de librería y dataset

library(ISLR2)

data(Credit)

# Dimensiones y resumen estadístico de la base

dim(Credit)

summary(Credit)

# Histograma de la variable a predecir (Balance)

hist(Credit$Balance, main = "Histograma de Agustín", col = "steelblue")

# Parte B - Conjuntos

# Carga de librería caret para la partición

library(caret)

# Partición en conjunto de entrenamiento (75%) y testeo (25%)

# Semilla: DNI (en este caso 42835505)

set.seed(42835505); particion = createDataPartition(y = Credit$Balance, p =
0.75, list = FALSE)

entreno = Credit[particion, ]

testeo = Credit[-particion, ]

# Exploración del conjunto de entrenamiento

head(entreno)

summary(entreno)

# Exploración del conjunto de testeo
```

```
head(testeo)
```

```
summary(testeo)
```

```
# Cantidad de registros en cada conjunto
```

```
dim(entreno)
```

```
dim(testeo)
```