

TRABAJO PRÁCTICO

Aprendizaje Supervisado



Agustín Musanti

14/06/2026

Certificación Avanzada en Data Science

PARTE A - PREPROCESAMIENTO DE LOS DATOS

- 1) Ingresa a la página web de la Universidad de California UCI

<https://archive.ics.uci.edu/dataset/236/seeds>.

Copie aquí el resumen que dice “Measurements of...”

Baje el archivo “seeds_dataset.txt”.

El resumen en cuestión dice:

“Measurements of geometrical properties of kernels belonging to three different varieties of wheat. A soft X-ray technique and GRAINS package were used to construct all seven, real-valued attributes.”

- 2) Busque en la página web, en el apartado “Additional Information:” e indique aquí: ¿cuáles son las 3 variedades de trigo que se estudiarán?

Según el apartado "Additional Information:" de la página de UCI, las tres variedades de trigo estudiadas son Kama, Rosa y Canadian.

- 3) Busque una imagen de granos de trigo. Indique la página web origen de dicha imagen.



La imagen de granos de trigo fue obtenida del siguiente sitio web:

<https://bolcereales.com.ar/wp-content/uploads/2020/02/Cereales-de-trigo.jpg>

4) Abra el archivo `seeds_dataset.txt` en R como "base".

Muestre un `head(base)`

A continuación se muestra el resultado:

```
head(base)
```

V1	V2	V3	V4	V5	V6	V7	V8
15.26	14.84	0.8710	5.763	3.312	2.221	5.220	1
14.88	14.57	0.8811	5.554	3.333	1.018	4.956	1
14.29	14.09	0.9050	5.291	3.337	2.699	4.825	1
13.84	13.94	0.8955	5.324	3.379	2.259	4.805	1
16.14	14.99	0.9034	5.658	3.562	1.355	5.175	1
14.38	14.21	0.8951	5.386	3.312	2.462	4.956	1

5) Las variables de la base representan los siguientes atributos de los granos de trigo:

V1=área de la semilla

V2=perímetro de la semilla

V3=compactitud

V4=largo de la semilla

V5=ancho de la semilla

V6=coeficiente de asimetría

V7=largo de la división frontal de la semilla

V8=variedad de la semilla (1-kama 2-rosa 3-canadian)

Renombre cada variable:

V1="Area"

V2="Perimetro"

V3="Compactitud"

V4="Largo"

V5="Ancho"

V6="Asimetria"

V7="Division"

V8="Tipo"

Muestre un head(base) con los cambios de variables.

Luego de efectuar los cambios correspondientes, la base queda de la siguiente manera:

head(base)

Area	Perimetro	Compactitud	Largo	Ancho	Asimetria	Division	Tipo
15.26	14.84	0.8710	5.763	3.312	2.221	5.220	1
14.88	14.57	0.8811	5.554	3.333	1.018	4.956	1
14.29	14.09	0.9050	5.291	3.337	2.699	4.825	1
13.84	13.94	0.8955	5.324	3.379	2.259	4.805	1
16.14	14.99	0.9034	5.658	3.562	1.355	5.175	1
14.38	14.21	0.8951	5.386	3.312	2.462	4.956	1

6) Transforme a categórica la variable Tipo y renombre las variedades 1, 2 y 3 como "kama", "rosa" y "canadian":

Muestre un **head(base)** para ver cómo quedaron las variables transformadas.

Nuevamente luego de efectuar los cambios, la base queda de la siguiente manera:

head(base)

Area	Perimetro	Compactitud	Largo	Ancho	Asimetria	Division	Tipo
15.26	14.84	0.8710	5.763	3.312	2.221	5.220	kama
14.88	14.57	0.8811	5.554	3.333	1.018	4.956	kama
14.29	14.09	0.9050	5.291	3.337	2.699	4.825	kama
13.84	13.94	0.8955	5.324	3.379	2.259	4.805	kama
16.14	14.99	0.9034	5.658	3.562	1.355	5.175	kama
14.38	14.21	0.8951	5.386	3.312	2.462	4.956	kama


PARTE B - ANÁLISIS EXPLORATORIO DE DATOS

1) ¿Cuántas semillas hay en total y por variedad?

La base contiene **210** semillas en total (**210** registros y **8** variables, según `dim(base)`). Distribuidas por variedad, hay **70** semillas de cada tipo: **70** Kama, **70** Rosa y **70** Canadian (`summary(base$Tipo)`). Se observa que el dataset está perfectamente balanceado entre las tres variedades.

2) Realice un gráfico de barras de la variable a predecir Tipo. Elija un Título.


Se realiza el gráfico eligiendo como título “Variedades de trigo”:



Se observa que las tres variedades están balanceadas.

3) Realice un gráfico de dispersión entre 2 variables (que no sean Tipo) y coloréalo por la variable Tipo (agregue una leyenda que indique cuál es cada grupo).

a) Para el título ingrese su nombre, como “Gráfico de SuNombre”.



Se realizó un gráfico de dispersión entre las variables **Largo** (eje X) y **Ancho** (eje Y), coloreado por la variable **Tipo**. Se observan tres grupos diferenciados: las semillas Canadian se concentran en valores menores de largo y ancho, las Rosa en los valores mayores, y las Kama ocupan una posición intermedia con cierto solapamiento hacia las otras dos variedades.

b) Indique el código R utilizado.

El código R utilizado para este gráfico fue:

```
library(caret)
```

```
xyplot(Ancho~Largo, groups=Tipo, base, auto.key=TRUE, main="Grafico de  
Agustin", pch=19)
```

4) Considere los 2 últimos dígitos de su DNI (2numDNI) y muestre aquí el registro correspondiente. ¿De qué variedad es?

Considerando los dos últimos dígitos del DNI (05), se seleccionó el registro número 5 de la base mediante `trigo=base[05,]`. Dicho registro corresponde a una semilla de la variedad **kama**.

```
trigo=base[05,]
trigo
  Area Perimetro Compactitud Largo Ancho Asimetria Division Tipo
16.14      14.99      0.9034 5.658 3.562      1.355      5.175 kama
```

PARTE C - CONJUNTOS

1) Considere su DNI (completo) para el seteo de semilla y particione la base en un conjunto de entrenamiento y uno de testeo.

- Además, si su DNI termina en 0, 1, 2 ó 3 **Setee p=0.70**
- Si su DNI termina en 4, 5, 6 ó 7 **Setee p=0.75**
- Si su DNI termina en 8 ó 9 **Setee p=0.80**

Indique cómo quedó el código R utilizado.

Considerando mi DNI (XXXX5505) como semilla y el valor $p = 0.75$ (dado que el DNI termina en 5), se particiona la base utilizando la función `createDataPartition` de la librería `caret`.

El código R utilizado fue:

```
set.seed(42835505); particion = createDataPartition(y = base$Tipo, p = 0.75,
list = FALSE)

entrenamiento = base[particion, ]

testeo = base[-particion, ]
```


2) Muestre un head y un summary del conjunto de entrenamiento y del conjunto de testeo.

Se ejecutan las instrucciones `head` y `summary` sobre ambos conjuntos para verificar la correcta partición de la base.

Conjunto de entrenamiento:

```
head(entreno)
```

Area	Perimetro	Compactitud	Largo	Ancho	Asimetria	Division	Tipo
15.26	14.84	0.8710	5.763	3.312	2.221	5.220	kama
14.88	14.57	0.8811	5.554	3.333	1.018	4.956	kama
14.29	14.09	0.9050	5.291	3.337	2.699	4.825	kama
16.14	14.99	0.9034	5.658	3.562	1.355	5.175	kama
14.11	14.10	0.8911	5.420	3.302	2.700	5.000	kama
16.63	15.46	0.8747	6.053	3.465	2.040	5.877	kama

```
summary(entreno)
```

Area		Perimetro		Compactitud		Largo	
Min.	:10.74	Min.	:12.57	Min.	:0.8081	Min.	:4.902
1st Qu.:	:12.20	1st Qu.:	:13.45	1st Qu.:	:0.8563	1st Qu.:	:5.247
Median	:14.37	Median	:14.35	Median	:0.8728	Median	:5.541
Mean	:14.80	Mean	:14.54	Mean	:0.8702	Mean	:5.625
3rd Qu.:	:17.19	3rd Qu.:	:15.70	3rd Qu.:	:0.8855	3rd Qu.:	:5.979
Max.	:20.88	Max.	:17.23	Max.	:0.9153	Max.	:6.675

Ancho		Asimetria		Division		Tipo	
Min.	:2.630	Min.	:0.7651	Min.	:4.519	kama	:53
1st Qu.:	:2.938	1st Qu.:	:2.5700	1st Qu.:	:5.045	rosa	:53
Median	:3.232	Median	:3.5970	Median	:5.224	canadian:	:53
Mean	:3.250	Mean	:3.6329	Mean	:5.407		
3rd Qu.:	:3.543	3rd Qu.:	:4.5050	3rd Qu.:	:5.877		
Max.	:4.032	Max.	:8.3150	Max.	:6.550		

Conjunto de testeo:

```
head(testeo)
  Area Perimetro Compactitud Largo Ancho Asimetria Division Tipo
1 13.84    13.94     0.8955 5.324 3.379    2.259    4.805 kama
2 14.38    14.21     0.8951 5.386 3.312    2.462    4.956 kama
3 14.69    14.49     0.8799 5.563 3.259    3.586    5.219 kama
4 15.26    14.85     0.8696 5.714 3.242    4.543    5.314 kama
5 13.89    14.02     0.8880 5.439 3.199    3.986    4.738 kama
6 13.78    14.06     0.8759 5.479 3.156    3.136    4.872 kama

> summary(testeo)
      Area      Perimetro    Compactitud      Largo
Min.   :10.59  Min.   :12.41  Min.   :0.8099  Min.   :4.899
1st Qu.:12.69  1st Qu.:13.48  1st Qu.:0.8587  1st Qu.:5.291
Median :14.16  Median :14.29  Median :0.8779  Median :5.479
Mean   :15.00  Mean   :14.61  Mean   :0.8734  Mean   :5.641
3rd Qu.:17.77  3rd Qu.:15.76  3rd Qu.:0.8932  3rd Qu.:6.078
Max.   :21.18  Max.   :17.25  Max.   :0.9183  Max.   :6.573
      Ancho      Asimetria      Division      Tipo
Min.   :2.641  Min.   :0.8551  Min.   :4.607  kama   :17
1st Qu.:2.985  1st Qu.:2.6525  1st Qu.:5.029  rosa   :17
Median :3.242  Median :3.6960  Median :5.219  canadian:17
Mean   :3.285  Mean   :3.9102  Mean   :5.413
3rd Qu.:3.616  3rd Qu.:5.1775  3rd Qu.:5.883
Max.   :4.033  Max.   :8.4560  Max.   :6.498
```

Se observa que las distribuciones de las variables son consistentes entre entrenamiento y testeo, con rangos y medias similares en todas las variables numéricas, lo que indica que la partición estratificada realizada con `createDataPartition` mantuvo la representatividad de los datos.

- 3) Realice un `summary(base$Tipo)` ;`summary(entreno$Tipo)` y un `summary(testeo$Tipo)`
¿Cuántos registros quedaron por variedad de trigo en el conjunto de entrenamiento y en el de testeo?

En el conjunto de entrenamiento quedaron 53 registros por variedad (53 kama, 53 rosa, 53 canadian), totalizando 159 semillas. En el conjunto de testeo quedaron 17 registros

por variedad (17 kama, 17 rosa, 17 canadian), totalizando 51 semillas. Se verifica que la partición estratificada con `createDataPartition` distribuyó las tres variedades de forma equitativa: $53 + 17 = 70$ por variedad, coincidiendo con el total original de la base.

```
summary(base$Tipo)
  kama      rosa  canadian
    70      70      70

summary(entreno$Tipo)
  kama      rosa  canadian
    53      53      53

summary(testeo$Tipo)
  kama      rosa  canadian
    17      17      17
```

PARTE D - ÁRBOL DE DECISIÓN

- 1) Cree un Árbol de Decisión (con librería `rpart`) para modelar el problema planteado. Escriba `print(arbol)` y muestre una captura de pantalla de la información que aparece.


La información que aparece al ejecutar el `print(arbol)` es la siguiente:

```
> arbol = rpart(Tipo ~ ., entreno)
> print(arbol)
n= 159

node), split, n, loss, yval, (yprob)
  * denotes terminal node

1) root 159 106 kama (0.333333333 0.333333333 0.333333333)
2) Division>=5.5755 53 1 rosa (0.018867925 0.981132075 0.000000000) *
3) Division< 5.5755 106 53 canadian (0.490566038 0.009433962 0.500000000)
6) Area>=12.71 54 7 kama (0.870370370 0.018518519 0.111111111)
12) Asimetria< 4.171 47 2 kama (0.957446809 0.021276596 0.021276596) *
13) Asimetria>=4.171 7 2 canadian (0.285714286 0.000000000 0.714285714) *
7) Area< 12.71 52 5 canadian (0.096153846 0.000000000 0.903846154)
14) Asimetria< 3.24 8 3 kama (0.625000000 0.000000000 0.375000000) *
15) Asimetria>=3.24 44 0 canadian (0.000000000 0.000000000 1.000000000) *
```

2) Grafique el Árbol de Decisión resultante con la librería `rpart.plot`.



3) ¿Cuántas “hojas” tiene el Árbol de Decisión?

El Árbol de Decisión tiene 5 hojas (nodos terminales): una que predice rosa, dos que predicen kama y dos que predicen canadian. Esto coincide con los nodos marcados con * en la salida de `print(arbol)`.

4) Según el Árbol de Decisión creado, ¿cuándo una semilla es de la variedad “rosa”? (Indique las reglas siguiendo las ramas desde el nodo raíz hasta las hojas “rosa”).

Según el Árbol de Decisión, una semilla se clasifica como variedad **rosa** cuando **Division**

≥ 5.5755 (en el gráfico, redondeado a **Division** ≥ 5.6). Esta es la primera división del árbol, partiendo desde el nodo raíz: la rama izquierda lleva directamente a la hoja "rosa", sin condiciones adicionales. En esa hoja caen **53** semillas, de las cuales **52** son efectivamente rosa, lo que la convierte en la regla más clara y confiable del modelo.

5) Calcule la matriz de confusión.

Muestre una captura de pantalla de los resultados completos (la matriz de confusión, accuracy y tablas).

Se calculó la matriz de confusión sobre el conjunto de testeo con **confusionMatrix** de la librería caret. Los resultados completos (matriz de confusión, accuracy y estadísticas por clase) se muestran en la captura a continuación. El modelo alcanzó un accuracy de **0.8627 (86,27%)** sobre las **51** semillas de testeo.

```
> pred = predict(arbol, testeo, type = "class")
> confusionMatrix(pred, testeo$Tipo)
Confusion Matrix and Statistics
```

	Reference		
Prediction	kama	rosa	canadian
kama	13	1	2
rosa	0	16	0
canadian	4	0	15

```
Overall Statistics

Accuracy : 0.8627
95% CI : (0.7374, 0.943)
No Information Rate : 0.3333
P-Value [Acc > NIR] : 7.453e-15

Kappa : 0.7941

Mcnemar's Test P-Value : NA

Statistics by Class:
```

	Class: kama	Class: rosa	Class: canadian
Sensitivity	0.7647	0.9412	0.8824
Specificity	0.9118	1.0000	0.8824
Pos Pred Value	0.8125	1.0000	0.7895
Neg Pred Value	0.8857	0.9714	0.9375
Prevalence	0.3333	0.3333	0.3333
Detection Rate	0.2549	0.3137	0.2941
Detection Prevalence	0.3137	0.3137	0.3725
Balanced Accuracy	0.8382	0.9706	0.8824

- 6) La cantidad de elementos de la matriz de confusión es igual a la cantidad de elementos de testeo (o sea `dim(testeo)`).
 Sume la cantidad de elementos de la diagonal de la matriz de confusión y divida el resultado por `dim(testeo)`.
 Muestre la cuenta con números y muestre que es igual al accuracy.

La diagonal de la matriz de confusión representa las predicciones correctas: **13** (kama) + **16** (rosa) + **15** (canadian) = **44** aciertos. El conjunto de testeo tiene **51** elementos (`dim(testeo)`). Dividiendo:

$$44/51 = 0.8627$$

El resultado coincide exactamente con el accuracy de **0.8627** reportado por `confusionMatrix`, lo que confirma que el accuracy es la proporción de elementos correctamente clasificados sobre el total.

- 7) Vea la tabla Statistics by Class debajo de la matriz de confusión e indique cuál clase presenta menor sensibilidad.

Según la tabla Statistics by Class, la clase con menor sensibilidad es **kama**, con una Sensitivity de **0.7647 (76.47%)**. Esto significa que el modelo solo identificó correctamente el 76% de las semillas kama reales: de las **17** kama del conjunto de testeo, **13** fueron clasificadas como kama y **4** fueron confundidas con canadian (como se ve en la columna kama de la matriz de confusión del punto 5). Es la variedad que el árbol tuvo más dificultad en detectar.

- 8) Prediga con el Árbol de Decisión el grano de trigo correspondiente a los últimos 2 dígitos de su DNI (el de la Parte B).
 ¿Coincide la variedad predicha por el Árbol de Decisión con la variedad original de la semilla?

Se predijo con el Árbol de Decisión la semilla correspondiente a los dos últimos dígitos del DNI (fila 5, variedad original kama) mediante `predict(arbol, trigo, type="class")`. El modelo predijo la variedad **kama**, que coincide con la variedad original de la semilla.

```
> predict(arbol, trigo, type="class")
5
kama
```

PARTE E - RED NEURONAL

- 1) Considere su DNI (completo) para el seteo de semilla y cree una Red Neuronal (con librería nnet) para modelar el problema planteado con **maxit=10000** y cantidad de neuronas en la capa oculta **size=25**. Indique el código R utilizado.

Se creó una Red Neuronal con la librería nnet, modelando Tipo en función de todas las variables predictoras, según indicaciones del enunciado. Se utilizó mi DNI completo como semilla para garantizar la reproducibilidad. El código quedó así:

```
library(nnet)
```

```
set.seed(42835505); red = nnet(Tipo ~ ., entreno, size = 25, maxit = 10000)
```

- 2) Muestre una captura de pantalla de la lista de iteraciones de la Red Neuronal.

Listado de iteraciones:

```
> library(nnet)
> set.seed(42835505); red = nnet(Tipo ~ ., entreno, size = 25, maxit = 10000)
# weights: 278
initial value 214.648372
iter 10 value 104.062853
iter 20 value 41.616361
iter 30 value 14.917045
iter 40 value 6.868256
iter 50 value 5.583952
iter 60 value 4.802523
iter 70 value 4.182577
iter 80 value 3.795595
iter 90 value 3.328258
iter 100 value 2.674971
iter 110 value 1.049554
iter 120 value 0.014476
iter 130 value 0.003003
iter 140 value 0.000880
iter 150 value 0.000497
iter 160 value 0.000304
iter 170 value 0.000250
final value 0.000097
converged
```

3) Escriba `print(red)` y muestre una captura de pantalla de la información que aparece.

Se observa la siguiente información:


```
> print(red)
a 7-25-3 network with 278 weights
inputs: Area Perimetro Compactitud Largo Ancho Asimetria Division
output(s): Tipo
options were - softmax modelling
```

4) Indique la cantidad de pesos y la cantidad de iteraciones resultantes.

La Red Neuronal resultó con **278 pesos** y convergió en aproximadamente **170 iteraciones**. Además, según `print(red)`, La arquitectura es una red 7-25-3 (7 variables de entrada, 25 neuronas en la capa oculta y 3 neuronas de salida correspondientes a las tres variedades)

5) Dibuje la Red Neuronal

Se dibujó la Red Neuronal con la instrucción `plotnet` de la librería **NeuralNetTools**, personalizando los colores de los nodos en azul, las conexiones de peso positivo en verde y las de peso negativo en rojo. Gráfico a continuación.



6) Calcule la matriz de confusión.

Muestre una captura de pantalla de los resultados completos (la matriz de confusión, accuracy y tablas).

Se calculó la matriz de confusión de la Red Neuronal sobre el conjunto de testeo con **confusionMatrix** de la librería caret. El modelo alcanzó un accuracy de **0.9608 (96.08%)** sobre las 51 semillas de testeo, clasificando correctamente **16 kama**, **16 rosa** y **17 canadian**, con solo **2 errores** en total. Los resultados completos (matriz, accuracy y estadísticas por clase) se muestran en la captura.

```
> confusionMatrix(factor(pred2), testeo$Tipo)
Confusion Matrix and Statistics

          Reference
Prediction kama  rosa  canadian
kama       16     1         0
rosa        0    16         0
canadian    1     0        17

Overall Statistics

          Accuracy : 0.9608
          95% CI   : (0.8654, 0.9952)
    No Information Rate : 0.3333
    P-Value [Acc > NIR] : < 2.2e-16

          Kappa : 0.9412

    McNemar's Test P-Value : NA

Statistics by Class:

               Class: kama Class: rosa Class: canadian
Sensitivity           0.9412           0.9412           1.0000
Specificity           0.9706           1.0000           0.9706
Pos Pred Value         0.9412           1.0000           0.9444
Neg Pred Value         0.9706           0.9714           1.0000
Prevalence             0.3333           0.3333           0.3333
Detection Rate         0.3137           0.3137           0.3333
Detection Prevalence   0.3333           0.3137           0.3529
Balanced Accuracy      0.9559           0.9706           0.9853
Aviso:
In confusionMatrix.default(factor(pred2), testeo$Tipo) :
  Levels are not in the same order for reference and data. Refactoring data to match.
```

7) ¿Cuál fue el accuracy?

El accuracy de la Red Neuronal fue de **0.9608 (96.08%)**.

- 8) Prediga con la Red Neuronal el grano de trigo correspondiente a los últimos 2 dígitos de su DNI (el de la Parte B).
¿Coincide la variedad predicha por la Red Neuronal con la variedad original de la semilla?

Se predijo con la Red Neuronal la semilla correspondiente a los dos últimos dígitos del DNI (fila 5, variedad original kama) mediante `predict(red, trigo, type="class")`.

La red predijo la variedad kama, que coincide con la variedad original de la semilla.

```
> predict(red, trigo, type="class")
[1] "kama"
```

PARTE F - COMPARACIÓN DE MODELOS

- 1) Cree una tabla con el accuracy de cada modelo, y la sensibilidad y especificidad de cada modelo por categoría.

Métrica	Árbol de Decisión	Red Neuronal
Accuracy (global)	0.8627	0.9608
Sensibilidad - kama	0.7647	0.9412
Sensibilidad - rosa	0.9412	0.9412
Sensibilidad - canadian	0.8824	1.0000
Especificidad - kama	0.9118	0.9706
Especificidad - rosa	1.0000	1.0000
Especificidad - canadian	0.8824	0.9706

- 2) Compare los resultados obtenidos con el Árbol de Decisión y la Red Neuronal.
¿Cuál modelo le parece que resultó mejor?

Al comparar ambos modelos sobre el mismo conjunto de testeo (51 semillas), la Red Neuronal resultó superior al Árbol de Decisión en prácticamente todas las métricas evaluadas.

En términos de accuracy global, la Red Neuronal alcanzó un **0.9608 (96.08%)** frente al **0.8627 (86.27%)** del Árbol de Decisión, una diferencia de casi **10** puntos porcentuales. Esto se traduce en cantidad de errores: el Árbol clasificó incorrectamente 7 de las **51** semillas, mientras que la Red Neuronal solo se equivocó en **2**.

Analizando las métricas por categoría, la Red Neuronal igualó o superó al Árbol en todas las clases, sin quedar por debajo en ninguna. La diferencia más marcada se da en la variedad kama, donde la sensibilidad del Árbol fue de **0.7647** (no detectó **4** de las **17** semillas kama, confundiéndolas con canadian) frente a **0.9412** de la Red Neuronal. La variedad rosa fue la mejor clasificada por ambos modelos (sensibilidad **0.9412** y especificidad **1.0000** en los dos casos), lo cual es coherente con el análisis exploratorio, donde rosa es la variedad más diferenciable, y de hecho el Árbol la separa con una sola regla (Division ≥ 5.5755).

Por lo tanto, la Red Neuronal resultó el mejor modelo para este problema de clasificación, tanto por su mayor accuracy como por su desempeño más parejo entre las tres variedades.

ANEXO - CÓDIGO R

```
# Parte A - Preprocesamiento de los datos

# Carga del dataset de granos de trigo

base = read.table("seeds_dataset.txt", header = FALSE)

head(base)

# Renombrado de las variables según los atributos de los granos

names(base)[names(base) == "V1"] = "Area"

names(base)[names(base) == "V2"] = "Perimetro"

names(base)[names(base) == "V3"] = "Compactitud"

names(base)[names(base) == "V4"] = "Largo"

names(base)[names(base) == "V5"] = "Ancho"

names(base)[names(base) == "V6"] = "Asimetria"

names(base)[names(base) == "V7"] = "Division"

names(base)[names(base) == "V8"] = "Tipo"

head(base)

# Transformación de la variable Tipo a categórica

base$Tipo = factor(base$Tipo, levels = c(1, 2, 3), labels = c("kama", "rosa",
"canadian"))

head(base)

# Parte B - Análisis Exploratorio de Datos

# Cantidad de semillas en total y por variedad

dim(base)

summary(base$Tipo)
```

```
# Gráfico de barras de la variable a predecir Tipo
plot(base$Tipo, main = "Variedades de trigo")

# Gráfico de dispersión entre Largo y Ancho, coloreado por Tipo
library(caret)

xyplot(Ancho ~ Largo, groups = Tipo, base, auto.key = TRUE, main = "Grafico
de Agustin", pch = 19)

# Registro correspondiente a los 2 últimos dígitos del DNI (05)

trigo = base[05, ]

trigo

# Parte C - Conjuntos

# Partición en entrenamiento (75%) y testeo (25%)

# Semilla es mi DNI completo (XXXX5505). DNI termina en 5 por lo tanto p=0.75

library(caret)

set.seed(XXXX5505); particion = createDataPartition(y = base$Tipo, p = 0.75,
list = FALSE)

entreno = base[particion, ]

testeo = base[-particion, ]

# head y summary de cada conjunto

head(entreno)

summary(entreno)

head(testeo)

summary(testeo)

# Cantidad de registros por variedad en cada conjunto

summary(base$Tipo)
```

```
summary(entreno$Tipo)

summary(testeo$Tipo)

# Parte D - Árbol de Decisión

# Creación del Árbol de Decisión con la librería rpart

library(rpart)

arbol = rpart(Tipo ~ ., entreno)

print(arbol)

# Gráfico del Árbol de Decisión

library(rpart.plot)

rpart.plot(arbol, extra = 1, type = 5)

# Matriz de confusión sobre el conjunto de testeo

pred = predict(arbol, testeo, type = "class")

confusionMatrix(pred, testeo$Tipo)

# Verificación: aciertos (diagonal) sobre total de testeo = accuracy

44/51

# Predicción de la semilla correspondiente al DNI

predict(arbol, trigo, type = "class")

# Parte E - Red Neuronal

# Creación de la Red Neuronal con la librería nnet

# Como semilla se utiliza mi DNI completo

library(nnet)

set.seed(XXXX5505); red = nnet(Tipo ~ ., entreno, size = 25, maxit = 10000)

# Información de la red
```

```
print(red)

# Gráfico de la Red Neuronal con colores personalizados

library(NeuralNetTools)

plotnet(red,
        circle_col = "lightsteelblue",  # nodos / neuronas
        pos_col    = "forestgreen",     # conexiones de peso positivo
        neg_col    = "firebrick",       # conexiones de peso negativos
        bord_col   = "gray40")          # borde de los nodos

# Matriz de confusión sobre el conjunto de testeo

pred2 = predict(red, testeo, type = "class")

confusionMatrix(factor(pred2), testeo$Tipo)

# Predicción de la semilla correspondiente al DNI

predict(red, trigo, type = "class")
```