

TRABAJO PRÁCTICO N°3

Aprendizaje No Supervisado



Agustín Musanti

42.835.505

Certificación Avanzada en Data Science

1) Abra la base cheddar de la librería faraway

Escriba **?cheddar** e indique de qué tratan cada una de las variables.

El dataset **cheddar** proviene de un estudio sobre queso cheddar del LaTrobe Valley (Victoria, Australia). A cada muestra de queso se le analizó su composición química y además se la sometió a pruebas de degustación. Cuenta con 30 observaciones y 4 variables, todas numéricas:

- **taste**: puntaje subjetivo de sabor. Es el resultado de combinar los puntajes de varios catadores (es la variable "de resultado" del estudio original).
- **Acetic**: concentración de ácido acético, en escala logarítmica.
- **H2S**: concentración de sulfuro de hidrógeno (ácido sulfhídrico), en escala logarítmica.
- **Lactic**: concentración de ácido láctico, en escala normal.

2) Muestre un **summary** de la base

A continuación se muestra lo solicitado:

```
> summary(cheddar)
```

taste	Acetic	H2S	Lactic
Min. : 0.70	Min. : 4.477	Min. : 2.996	Min. : 0.860
1st Qu.: 13.55	1st Qu.: 5.237	1st Qu.: 3.978	1st Qu.: 1.250
Median : 20.95	Median : 5.425	Median : 5.329	Median : 1.450
Mean : 24.53	Mean : 5.498	Mean : 5.942	Mean : 1.442
3rd Qu.: 36.70	3rd Qu.: 5.883	3rd Qu.: 7.575	3rd Qu.: 1.667
Max. : 57.20	Max. : 6.458	Max. : 10.199	Max. : 2.010

3) Considere su DNI (completo) para el seteo de la semilla y realice un agrupamiento kmeans.

- Además, si su DNI termina en 0, 1, 2 ó 3

Cantidad de grupos = 3

- Si su DNI termina en 4, 5, 6 ó 7

Cantidad de grupos = 4

- Si su DNI termina en 8 ó 9

Cantidad de grupos = 5

Deje el resto de los parámetros por defecto.

Indique cómo quedó el código R utilizado.

Considerando mi DNI (42835505) como semilla y la cantidad de grupos = 4 (dado que el DNI termina en 5), realicé el agrupamiento k-means con el siguiente código, dejando el resto de los parámetros por defecto:

```
set.seed(42835505); km = kmeans(cheddar, 4)
```

4) ¿Cuántos elementos quedaron en cada grupo?

Ejecutando `km$size` obtuve la cantidad de elementos por grupo:

- Grupo 1: 7 elementos
- Grupo 2: 13 elementos
- Grupo 3: 4 elementos
- Grupo 4: 6 elementos

En total suman 30, que coincide con la cantidad de observaciones de la base.

```
> km$size  
[1]  7 13  4  6
```

5) Muestre `km$cluster` ¿A qué grupo pertenece el último elemento de la base?

Ejecutando `km$cluster` se obtiene el grupo asignado a cada una de las 30 observaciones. El último elemento de la base pertenece al grupo 1.

```
> km$cluster  
[1] 1 2 4 3 1 2 4 2 2 2 4 3 1 2 3 4 2 1 2 4 2 2 4 3 2 1 2 1 2 1
```

6) Muestre una captura de pantalla de los centroides

```
> km$centers
      taste  Acetic      H2S   Lactic
1  6.114286 5.234571 3.793714 1.194286
2 19.500000 5.371692 5.472462 1.380769
3 54.175000 6.052750 8.088750 1.810000
4 37.166667 5.709333 8.033333 1.618333
```

7) Determine alguna característica de alguno de los grupos con respecto a los otros grupos.

Analizando los centroides, el **grupo 3** se distingue claramente de los demás ya que presenta el puntaje de sabor (taste **54.17**) más alto de todos, muy por encima de los grupos 1 (**6.11**), 2 (**19.5**) y 4 (**37.16**). Además, es el grupo con mayores concentraciones de los tres compuestos químicos (Acetic, H2S y Lactic). En el extremo opuesto, el grupo **1** reúne los quesos de menor sabor y menores concentraciones químicas. Esto sugiere que el k-means agrupó las muestras siguiendo un gradiente de intensidad donde a mayor concentración de ácidos y sulfuro de hidrógeno, mayor es el puntaje de sabor del queso.

ANEXO - CÓDIGO R

```
# Carga de la librería y del dataset cheddar

library(faraway)

data(cheddar)

# Documentación de la base y sus variables

?cheddar

# Punto 2 - Resumen de la base

summary(cheddar)

# Punto 3 - Agrupamiento k-means

# Como semilla utilizo mi DNI(42835505), cantidad de grupos = 4

# Resto de los parámetros por defecto

set.seed(42835505); km = kmeans(cheddar, 4)

# Punto 4 - Cantidad de elementos por grupo

km$size

# Punto 5 - Grupo asignado a cada observación

km$cluster

# Punto 6 - Centroides de cada grupo

km$centers
```